

Reporte técnico: Sistema RAG

Proyecto Final | Maestría en Inteligencia Artificial

1. Dominio y Tamaño del Corpus

El sistema fue alimentado con un corpus documental de naturaleza mixta, abarcando material académico y de entretenimiento. El conjunto de datos consta de **documentos en formato PDF y TXT** (incluyendo artículos sobre competencias universitarias para el desarrollo sostenible, infografías, apuntes de la semana 5 y datos estructurados sobre la serie *Los Soprano*).

En total, el corpus contiene miles de palabras que, tras el procesamiento, generaron un volumen robusto de fragmentos (*chunks*). Para la representación vectorial del texto se utilizó el modelo de **Google AI text-embedding-004** (o equivalente de la familia Gemini), el cual transforma tanto los documentos ingeridos como las preguntas del usuario en espacios vectoriales de alta dimensionalidad, permitiendo búsquedas semánticas precisas.

2. Estrategia de Particionado (Chunking)

El texto crudo extraído de los documentos fue dividido utilizando la siguiente configuración técnica:

- **Tamaño del fragmento (Chunk Size):** 200 palabras/tokens.
- **Solapamiento (Overlap):** 50 palabras/tokens.

```
77     # 3. Partir en chunks
78     chunks = get_chunks(text, chunk_size=200, overlap=50)
79
80     if not chunks:
81         raise HTTPException(status_code=400, detail="El documento no contiene texto válido.")
82
```

Se seleccionó este tamaño porque 200 palabras capturan de manera óptima una idea o concepto completo dentro de un párrafo estándar, facilitando que el LLM tenga el contexto exacto sin diluir la información con datos irrelevantes. El *overlap* de 50 palabras funciona como una "red de seguridad" semántica: garantiza que las ideas o sentencias que ocurren justo en el límite entre dos fragmentos no pierdan su significado ni su contexto, evitando cortes abruptos en explicaciones críticas.

3. Mecanismo de Abstención (Prevención de Alucinaciones)

Para garantizar la fiabilidad del sistema RAG, la abstención no se basa en el conocimiento paramétrico del modelo, sino en un **enfoque de Prompting Estricto (Strict Prompting)**.

Al momento de generar la respuesta, se le inyecta a Gemini una regla condicional absoluta: si la "Evidencia Recuperada" no contiene la información necesaria para responder a la pregunta, el modelo tiene estrictamente prohibido usar su memoria interna y debe retornar un *token* clave específico (NO_HAY_EVIDENCIA). El backend de FastAPI intercepta esta palabra clave antes de enviarla a la interfaz de Streamlit, transformándola en un booleano (`abstained = True`) que dispara alertas visuales en la interfaz de usuario, cumpliendo así con la regla de oro: "si no está en el corpus, el sistema no lo sabe".

4. Arquitectura de Generación y Recuperación (Google AI vs ChromaDB)

El sistema desacopla claramente las responsabilidades entre la base de datos vectorial y los modelos fundacionales de Google:

- **Google AI (Embeddings):** Es el motor matemático. Recibe texto en lenguaje natural y devuelve vectores numéricos. Se llama en dos momentos: durante la ingesta (para traducir los documentos) y durante la inferencia (para traducir la pregunta del usuario).
- **ChromaDB (Búsqueda y Persistencia):** Actúa como el almacenamiento local estructurado. No genera embeddings por sí mismo; recibe los vectores de Google AI y los guarda junto con sus metadatos (el archivo de origen *source* y el texto del *chunk*). Su tarea principal en inferencia es ejecutar un algoritmo **k-NN (k-Nearest Neighbors)** utilizando la métrica de similitud del coseno para devolver los fragmentos matemáticamente más cercanos a la pregunta.
- **Google AI (Generación):** Utilizando el modelo *gemini-1.5-flash* (o *gemini-3.8-flash*), actúa como la capa de razonamiento final. Recibe únicamente los *chunks* que ChromaDB consideró relevantes, los procesa como contexto cerrado y redacta una respuesta coherente en lenguaje natural, añadiendo las citas bibliográficas [n] correspondientes.

5. Análisis del Comportamiento del RAG (Conclusiones del Sistema)

Durante las pruebas de inferencia, se evaluó el sistema con consultas compuestas, como: "*¿Quién dirigió Los Soprano y quién fue Christopher Moltisanti?*". El análisis de esta consulta reveló dos comportamientos avanzados de la arquitectura:

1. **Recuperación Semántica vs. Léxica:** Aunque el documento original indica explícitamente "*creada por...*" y la pregunta utilizaba el verbo "*dirigió*", el modelo de *embeddings* logró capturar la similitud semántica y recuperó con éxito el Chunk [1], demostrando que el sistema comprende la intención del usuario y no depende de coincidencias exactas de palabras.
2. **Abstención Estricta ("Todo o Nada"):** Al ejecutar la prueba con un `top_k=3`, el sistema recuperó el Chunk [1] (información del creador), pero la información de Christopher Moltisanti quedó fuera del alcance de recuperación. Al no tener la evidencia completa, el modelo prefirió abstenerse en su totalidad en lugar de alucinar la segunda parte o dar una respuesta parcial. Al incrementar la ventana de contexto a `top_k=5`, el sistema logró ingresar el Chunk [4] a la memoria a corto plazo del LLM (el cual contenía la biografía del personaje). Una vez satisfechos ambos criterios con evidencia real, el modelo abandonó la abstención e imprimió la respuesta íntegra y citada. Esto valida la robustez del mecanismo anti-alucinaciones.



6. Conclusión Personal

El desarrollo de este proyecto integrador ha sido un hito fundamental en mi formación dentro de la Maestría en Inteligencia Artificial. Construir un pipeline RAG desde cero —orquestrando FastAPI, ChromaDB, los modelos de Google AI y Streamlit— me ha permitido comprobar de primera mano que la eficacia de un modelo fundacional no depende únicamente de su tamaño o entrenamiento, sino de la calidad de la arquitectura de recuperación que lo alimenta.

El análisis del comportamiento del `top-k` fue una revelación práctica sobre la ingeniería de sistemas conversacionales: un contexto demasiado estrecho genera omisiones, pero un límite bien calibrado,

combinado con un *prompt* riguroso, otorga total seguridad sobre las respuestas. Personalmente, me llevo la profunda lección de que obligar a una IA a "saber decir que no sabe" es el paso más crítico para llevar estos modelos del entorno académico a soluciones empresariales reales y confiables.

Evidencias



Dr. Victor Uc Co. x RAG.pptx x Copia de u1_n1 x Rate Limit | Go x inteligencia-arti x MIA-Ramayo/Pi x Explicación de x RAG App x Sistema RAG - P x +

localhost:8501

Deploy

La formación de competencias básicas para el desarrollo sostenible el papel de la Universidad.pdf

datos_para_rag_los_soprano.txt

Configuración

Fragments a recuperar (Top-K): 5

Filtro de Búsqueda

Consultar en: Todos los documentos

Limpiar historial de chat

26°C Parc. nublado

"Los Soprano" fue creada por David Chase [1]. Christopher Moltisanti es el protegido y "sobrino" de Tony Soprano (técnicamente primo de Carmela), quien lucha con fuertes adicciones a las drogas y tiene aspiraciones frustradas de ser guionista de Hollywood [4].

Ver Evidencia Recuperada (Citas)

[1] Fuente: datos_para_rag_los_soprano.txt (Distancia: 0.5671)

Título: Los Soprano - Resumen y Datos Clave para Recuperación de Información Visión General: "Los Soprano" (The Sopranos) es una serie de televisión estadounidense de drama criminal creada por David Chase. Se estrenó en la cadena HBO el 10 de enero de 1999 y concluyó el 10 de junio de 2007, contando con un total de 6 temporadas y 86 episodios. La serie es ampliamente considerada como una de las mejores y más influyentes en la historia de la televisión, marcando el inicio de lo que muchos críticos llaman la "Segunda Edad de Oro de la televisión". Sinopsis Principal: La historia se centra en Tony Soprano, un mafioso italoestadounidense con sede en Nueva Jersey. La trama explora sus constantes dificultades para equilibrar su vida familiar suburbana con su papel como líder de una organización criminal. Las presiones de gestionar estas "dos familias" lo llevan a sufrir severos ataques de pánico, motivo por el cual comienza a asistir a sesiones de terapia confidenciales con la psiquiatra Jennifer Melfi. Personajes Principales y Relaciones: Tony Soprano (interpretado por James Gandolfini): El protagonista. Es un jefe de la mafia (DiMeo crime family) que lucha con la depresión, problemas de control de ira y

[2] Fuente: datos_para_rag_los_soprano.txt (Distancia: 0.5671)

Título: Los Soprano - Resumen y Datos Clave para Recuperación de Información Visión General: "Los Soprano" (The Sopranos) es una serie de televisión estadounidense de drama criminal creada por David Chase. Se estrenó en la cadena HBO el 10 de enero de 1999 y concluyó el 10 de junio de 2007, contando con un total de 6 temporadas y 86 episodios. La serie es ampliamente considerada como una de las mejores y más influyentes en la historia de la televisión, marcando el inicio de lo que muchos críticos llaman la "Segunda Edad de Oro de la televisión". Sinopsis Principal: La historia se centra en Tony Soprano, un mafioso italoestadounidense con sede en Nueva Jersey. La trama explora sus constantes dificultades para equilibrar su vida familiar suburbana con su papel como líder de una organización criminal. Las presiones de gestionar estas "dos familias" lo llevan a sufrir severos ataques de pánico, motivo por el cual comienza a asistir a sesiones de terapia confidenciales con la psiquiatra Jennifer Melfi. Personajes Principales y Relaciones: Tony Soprano (interpretado por James Gandolfini): El protagonista. Es un jefe de la mafia (DiMeo crime family) que lucha con la depresión, problemas de control de ira y

Haz una pregunta sobre tus documentos...

Dr. Victor Uc Co. x RAG.pptx x Copia de u1_n1 x Rate Limit | Go x inteligencia-arti x MIA-Ramayo/Pi x Explicación de x RAG App x Sistema RAG - P x +

localhost:8501

Deploy

La formación de competencias básicas para el desarrollo sostenible el papel de la Universidad.pdf

datos_para_rag_los_soprano.txt

Configuración

Fragments a recuperar (Top-K): 5

Filtro de Búsqueda

Consultar en: Todos los documentos

Limpiar historial de chat

26°C Parc. nublado

[3] Fuente: datos_para_rag_los_soprano.txt (Distancia: 0.5671)

Título: Los Soprano - Resumen y Datos Clave para Recuperación de Información Visión General: "Los Soprano" (The Sopranos) es una serie de televisión estadounidense de drama criminal creada por David Chase. Se estrenó en la cadena HBO el 10 de enero de 1999 y concluyó el 10 de junio de 2007, contando con un total de 6 temporadas y 86 episodios. La serie es ampliamente considerada como una de las mejores y más influyentes en la historia de la televisión, marcando el inicio de lo que muchos críticos llaman la "Segunda Edad de Oro de la televisión". Sinopsis Principal: La historia se centra en Tony Soprano, un mafioso italoestadounidense con sede en Nueva Jersey. La trama explora sus constantes dificultades para equilibrar su vida familiar suburbana con su papel como líder de una organización criminal. Las presiones de gestionar estas "dos familias" lo llevan a sufrir severos ataques de pánico, motivo por el cual comienza a asistir a sesiones de terapia confidenciales con la psiquiatra Jennifer Melfi. Personajes Principales y Relaciones: Tony Soprano (interpretado por James Gandolfini): El protagonista. Es un jefe de la mafia (DiMeo crime family) que lucha con la depresión, problemas de control de ira y

[4] Fuente: datos_para_rag_los_soprano.txt (Distancia: 0.5705)

motivo por el cual comienza a asistir a sesiones de terapia confidenciales con la psiquiatra Jennifer Melfi. Personajes Principales y Relaciones: Tony Soprano (interpretado por James Gandolfini): El protagonista. Es un jefe de la mafia (DiMeo crime family) que lucha con la depresión, problemas de control de ira y complejas dinámicas familiares. - Carmela Soprano (interpretada por Edie Falco): La esposa de Tony. Lucha constantemente con la moralidad de las acciones de su marido y el origen de su dinero, aunque disfruta del estatus y confort que este le proporciona. - Dra. Jennifer Melfi (interpretada por Lorraine Bracco): La psiquiatra de Tony. La dinámica de sus sesiones de terapia es uno de los pilares narrativos de la serie, sirviendo como ventana a la mente del criminal. - Christopher Moltisanti (interpretado por Michael Imperioli): Protegido y "sobrino" de Tony (aunque técnicamente es primo de Carmela). Lucha con fuertes adicciones a las drogas y tiene aspiraciones frustradas de ser guionista de Hollywood. - Corrado "Junior" Soprano (interpretado por Dominic Chianese): El tío de Tony. Inicialmente es el jefe oficial de la familia criminal, pero es utilizado por Tony como pararrayos para el FBI, mientras Tony maneja el poder real en la

[5] Fuente: datos_para_rag_los_soprano.txt (Distancia: 0.5705)

motivo por el cual comienza a asistir a sesiones de terapia confidenciales con la psiquiatra Jennifer Melfi. Personajes Principales y Relaciones: Tony Soprano

Haz una pregunta sobre tus documentos...

La formación de competencias básicas para el desarrollo sostenible el papel de la Universidad.pdf

datos_para_rag_soprano.txt

Configuración

Fragmentos a recuperar (Top-K):
3

Filtro de Búsqueda

Consultar en:
Todos los documentos

Limpiar historial de chat

[3] Fuente: datos_para_rag_soprano.txt (Distancia: 0.5131)

Título: Los Soprano - Resumen y Datos Clave para Recuperación de Información
Visión General: "Los Soprano" (The Sopranos) es una serie de televisión estadounidense de drama criminal creada por David Chase. Se estrenó en la cadena HBO el 10 de enero de 1999 y concluyó el 10 de junio de 2007, contando con un total de 6 temporadas y 86 episodios. La serie es ampliamente considerada como una de las mejores y más influyentes en la historia de la televisión, marcando el inicio de lo que muchos críticos llaman la "Segunda Edad de Oro de la televisión".
Sinopsis Principal: La historia se centra en Tony Soprano, un mafioso italoestadounidense con sede en Nueva Jersey. La trama explora sus constantes dificultades para equilibrar su vida familiar suburbana con su papel como líder de una organización criminal. Las presiones de gestionar estas "dos familias" lo llevan a sufrir severos ataques de pánico, motivo por el cual comienza a asistir a sesiones de terapia confidenciales con la psiquiatra Jennifer Melfi.
Personajes Principales y Relaciones: - Tony Soprano (interpretado por James Gandolfini): El protagonista. Es un jefe de la mafia (DiMeo crime family) que lucha con la depresión, problemas de control de ira y

quien dirigió los soprano? quien fue cristopher moltisanti?

No tengo evidencia suficiente en los documentos proporcionados para responder a esa pregunta.

Ver Evidencia Recuperada (Citas)

Regenerar respuesta

Haz una pregunta sobre tus documentos...

26°C
Parc. nublado

Windows Taskbar Icons

ESP

12:28 a. m.
05/10/2026